

1. Importación de datos y librerías

Partimos de un archivo CSV con datos de 10.000 clientes y su consumo energético. El objetivo es entender los datos.

Empezamos importando las librerías *pandas* (análisis de datos), *numpy* (cálculo científico), *matplotlib* y *seaborn* (para gráficos). Después, importamos y verificamos las columnas para asegurarnos de que el archivo tiene los campos esperados, así como los tipos de sus datos, valores *null* y duplicados.

2. Limpieza de datos

El primer paso de la limpieza de datos es convertir la fecha con *to_datetime* para que pase de un texto (*string*) a un valor que la librería *pandas* entiende como fechas reales (YYYY-MM-DD). Se crea la variable “*num_mes*” para poder agrupar los registros por mes y ver tendencias.

Se utiliza el IQR para el análisis de *outliers*, que se trata de la distancia entre el percentil 25 y el 75 (el rango central de los datos) y cualquier valor que se aleje más de 1.5 veces de ese rango se considera *outlier*. Sin embargo, vemos que el número de este tipo de datos en nuestro *dataset* es 0, por lo que los datos son muy limpios.

Utilizamos estadísticas descriptivas para entender dónde se encuentra la “normalidad” de los datos antes de avanzar en el análisis. En este caso, *mean* (media) = 5.051 y *standard deviation* (mediana) = 2.867 indican una distribución simétricas (una gran diferencia serían señal de sesgo).

3. Gráficas en el notebook

El histograma de distribución por columnas nos muestra cómo se reparten los valores de cada variable. Así, observamos que el tanto el consumo de kWh y Co2 tienen una distribución uniforme, por lo que se entiende que hay clientes de todo tipo por igual, sin un perfil “típico” o “fijo”. El coste por kWh está concentrado entre 0.10 y 0.25 en forma de U, por lo que hay muchos clientes con tarifas extremas (o muy caras o muy baratas), y pocos en el medio. El coste total cae hacia la derecha, es decir, la mayoría de clientes paga poco; este sesgo tiene sentido ya que el coste total depende del consumo. Por último, el porcentaje de energía renovable muestra una distribución uniforme, sin una tendencia clara a ningún extremo (0% y 100% renovable).

Las tablas de agrupación por región y contrato también nos dan información interesante. En términos de región, la zona norte tiene el mayor consumo por lo que es la de mayor demanda energética; la zona oeste tiene más emisiones pese a tener menos registros debido a que su mix energético es el más contaminante; la zona este es la que mayor consumo renovable tiene. En términos del tipo de contrato, vemos que no hay apenas diferencia entre si se trata de uno Residencia o uno Comercial, ya que la diferencia máxima en consumo medio es apenas 10kWh; con esto, podemos concluir que el tipo de contrato no discrimina el comportamiento energético. Estos datos podemos analizarlos también visualmente mediante gráfico de barras. Por un lado, las gráficas de barras horizontales nos muestra el consumo medio por región, que es prácticamente igual en todas las regiones. Esto confirma visualmente lo indicado en la tabla: no hay región que destaque claramente. La similitud en gráficas es señal de que la segmentación por región en sí misma no explica el consumo. Por otro lado, las barras por contrato muestran que ambas llegan prácticamente al 49% indicado en los datos, lo que confirma que el tipo de contrato no influye en la adopción de renovables.

Al realizar un mapa de correlación (*heatmap*) podemos observar la correlación entre dos variables. Cada celda se muestra en un color que van acorde a la varianza numérica en relación a la variación cromática: el verde oscuro muestra una correlación alta (valor = 1) y el amarillo, que no hay

correlación (valor = 0). Las correlaciones más importantes que observamos son entre consumo y porcentaje de renovable (0.89), consumo y coste total (0.89), consumo y CO2 (-0.01, nula) y CO2 y porcentaje de renovable (-0.01). El hallazgo más importante es que consumir más kWh no genera más CO2, y este ocurre porque el CO2 depende del mix energético y no del volumen. Es curioso que haya una correlación alta entre consumo y porcentaje de renovable porque los clientes que más consumen tienden a tener más renovable en su contrato. Podemos suponer que se tratan de clientes más grandes que han negociado tarifas más verdes.

A continuación, utilizamos un *boxplot* (diagrama de cajas), que resume la distribución en 5 números: el mínimo, el Q1, la mediana, el Q3 y el máximo (muy parecido al IQR). Al revisar los *outliers* de las agrupaciones por contrato, observamos que ambas cajas son prácticamente idénticas: una media de ~5.000kWh en un rango de 0 a 10.000. No hay *outliers* visibles, lo que confirma los datos dados por el análisis IQR: los contratos Residencial y Comercial se comportan igual. Al hacer el análisis por región vemos que las 5 cajas son prácticamente iguales: mismo rango, misma mediana y misma dispersión. En conclusión, la región no explica la diferencia de consumo. Ambos gráficos nos dan la misma información, los datos están distribuidos de forma muy homogénea sin grupos que destaquen.

El último análisis se centra en la tendencia mensual mediante un gráfico de doble eje. Aquí se mezclan barras (consumo medio mensual en kWh) y una línea naranja (el porcentaje de renovable medio). Podemos observar que el consumo (barras) es muy estable todo el año, con una ligera subida en noviembre, pero sin picos estacionales claros. El porcentaje de renovable oscila bastante ya que sube en agosto y cae con fuerza en octubre-noviembre (una diferencia de casi 10 puntos), lo que puede indicar la diferencia en generación solar/eólica disponible en el mix. La caída más notable en renovable es en noviembre, y sería interesante ver su avance en el mes de diciembre. La conclusión es que el consumo es predecible y estable, mientras que la calidad energética varía con la estacionalidad. Esto abre oportunidades para programas compensatorios en los meses de menos porcentaje renovable.

4. Gráficas de Looker Studio

Tras crear un csv con datos limpios para tratar el Google Looker Studio, hemos realizado gráficas en tres apartados: a) métricas clave, b) series temporales, y c) gráficas comparativas por región y tipo de contrato.

a) Métricas clave

De acuerdo a los datos individuales y a los gráficos de tarta, podemos observar que del consumo total, apenas hay diferencia entre los tipos de contrato (50.7% comercial, 49.3% residencial).

En emisiones totales vemos que hay una repartición uniforme de manera mensual, sin que uno destaque por encima de otro. Dentro del coste total, la región norte lidera con 20.8% y el oeste es la región más baja con 18.7%; es decir, hay una diferencia mínima de 2 puntos entre el coste más caro y el más barato.

Observamos que tampoco hay diferencia de precio en el coste medio por kWh según el tipo de contrato (50.2% comercial, 49.8% residencial).

b) series temporales (enero-noviembre 2024)

En el consumo medio observamos que este es muy estable a lo largo del año (entre 49K y 52K), pero tiene una notable subida en noviembre que puede indicar el inicio de uso de la calefacción.

Las emisiones medias tienen dos picos claros en mayo (~10.5K) y en septiembre (~10.6K) con un periodo valle en junio y julio (~9.8K). Esto refuerza las conclusiones del mapa de correlación (*heatmap*) ya que las emisiones no siguen al consumo, si no que dependen del mix energético disponible en cada mes.

El coste medio por kWh oscila entre 1.73 y 1.77 a lo largo del tiempo, un rango muy estrecho de apenas 0.04 céntimos de diferencia. Hay dos picos en febrero y agosto, que coinciden con los picos de emisiones: cuando el mix tiene menos renovables, más energía fósil se usa y es más cara. De nuevo, se ve el alza en noviembre de cara al invierno.

c) gráficas comparativas por región y contrato

En términos de región, observamos que la zona norte lidera en los tres indicadores (consumo, emisiones y coste), mientras que la zona oeste es la más eficiente de las tres. En estos términos, vemos que el norte consume más, contamina más y paga más.

En términos de contrato, observamos una ligera superioridad del contrato comercial sobre el residencial en las tres métricas con diferencias muy pequeñas (~5% en consumo, ~4% en emisiones, y ~5% en coste). Con esto, se corrobora que el tipo de contrato no explica el comportamiento energético.

5. Conclusiones

La región norte es la prioritaria para realizar una intervención debido a sus métricas de consumo, emisiones y coste.

Las emisiones tienen una estacionalidad desligada del consumo.

El consumo y el coste kWh tienden al alza en noviembre, que marca el inicio de una tendencia de mayor consumo y gasto.

El precio energético va en consonancia con el mix (renovable + fósil) y no de acuerdo al volumen (consumo).